

视频生成模型发展讲义

从扩散模型到可交互世界模型

整理日期：2026 年 9 月 12 日

目录

1	学习路线	1
2	视频表示与扩散基础	1
3	关键模型	1
3.1	Genie：从生成视频到生成环境	1
3.2	HunyuanVideo	2
3.3	Wan 2.1	2
3.4	MiniMax Hailuo-02 与 H3	2
3.5	SANA-Video	2
3.6	LingBot 与 FLUX.3	2
4	时间线与对比	2
5	榜单阅读原则	3
6	问题驱动的发展脉络与论文原图	4
6.1	Genie：为什么要从生成视频转向生成环境？	4
6.2	HunyuanVideo：如何让开源 Video DiT 接近闭源质量？	4
6.3	Wan 2.1：如何把 T2V、I2V 与编辑统一到一个开放基线？	4
6.4	SANA-Video：当 token 数成为显存瓶颈，如何生成分钟级视频？	4
6.5	LingBot-Video：如何把“好看”推进到“可执行”？	6
6.6	如何比较这些图？	6
7	原图资产索引	6
8	世界模型延伸阅读	8

9 2025–2026 扩展：代表性 SOTA 与架构进展	8
9.1 Step-Video-T2V：深压缩 VAE 与视频 DPO	8
9.2 HunyuanVideo 1.5：选择性滑窗注意力与级联超分	9
9.3 Epona：视频世界模型与轨迹规划解耦	9
9.4 SkyReels V2–V4：长片、参考一致性和音视频统一	10
9.5 LanDiff、FlashVideo 与 FSVideo：语义先行和极限加速	10
9.6 长视频稳定性：Endless World、Cycle-World、BAGger 与 Diagonal Distillation	10
10 Xun Huang 博客的统一视角	10

1 学习路线

本讲义按“视频表示—扩散与 DiT—效率—多模态—世界模型”递进。先理解 3D-VAE 如何把像素压缩成时空 latent，再比较 DDPM 与 Flow Matching，最后说明 Genie 和 LingBot 为什么需要动作条件与物理奖励。

2 视频表示与扩散基础

早期 VideoGPT、DVD-GAN 在像素或离散 VQ-VAE token 上自回归，因果性好但序列很长。Make-A-Video、Imagen Video 将图像扩散迁移到时空 U-Net。Sora 之后，主流改为 3D-VAE 潜空间与 Diffusion Transformer (DiT)。设视频 latent 为 $z_0 \in \mathbb{R}^{T \times H \times W \times C}$ ，DDPM 损失为

$$\mathcal{L}_{\text{DDPM}} = \mathbb{E}_{z_0, \epsilon, t} \|\epsilon - \epsilon_\theta(z_t, t, c)\|_2^2.$$

Flow Matching 直接学习速度场：

$$\mathcal{L}_{\text{FM}} = \mathbb{E}_{t, z_0, z_1} \|v_\theta(z_t, t, c) - (z_0 - z_1)\|_2^2.$$

视频 token 数 $N = THW$ ，全注意力复杂度 $O(N^2)$ ，是长视频的主要瓶颈。

3 关键模型

3.1 Genie：从生成视频到生成环境

Genie (DeepMind, 2024) 论文：[arXiv:2402.15391](https://arxiv.org/abs/2402.15391)。约 11B 参数，包含时空 tokenizer、从相邻帧推断离散 latent action 的模型，以及根据历史状态和动作预测下一 latent 的自回归 dynamics。它逐帧 rollout 并接受键盘/鼠标控制，学习目标是环境转移而非一次性 T2V 画面。

3.2 HunyuanVideo

腾讯 HunyuanVideo (2024) 论文: [arXiv:2412.03603](#), [代码](#)。13B DiT 使用因果 3D-VAE (时间、空间、通道压缩约 4、8、16 倍), MLLM 编码文本, Transformer 采用 dual-stream 到 single-stream: 先分别调制视频和文本 token, 后段拼接并做全注意力融合。联合图像/视频训练, 支持 T2V、I2V、V2V 编辑和个性化。

3.3 Wan 2.1

Wan (2025) 论文: [arXiv:2503.20314](#), [代码](#)。提供 1.3B/14B, 使用因果 Wan-VAE、DiT、Flow Matching、文本 cross-attention 和全时空注意力, 覆盖 T2V、I2V、V2V 编辑、个性化等任务。1.3B 约 8.2GB 显存, 14B 质量高但推理慢。

3.4 MiniMax Hailuo-02 与 H3

Hailuo-02 使用 Noise-aware Compute Redistribution (NCR) 按噪声阶段分配计算, 官方宣称约 2.5 倍效率提升 ([官方介绍](#))。MiniMax H3 (2026-07-31, [官方博客](#)) 以 Contextual Omni Representation、H3-VAE、H3-Omni Transformer 和 In-Context Regeneration 统一文字、图像、视频、音频, 最高 2K/15 秒并原生生成立体声音频。权重开放状态应以最新公告为准。

3.5 SANA-Video

SANA-Video (2025) 论文: [arXiv:2509.24695](#)。Linear DiT 和块式自回归使用恒定内存 KV 状态, 支持分钟级 720×1280; 实测延迟约为 Wan-1.3B 的 1/16。SANA-Video 2.0 5B 采用 75% 线性注意力、25% softmax anchor、Attention Residual 和 LTX-2.3 VAE, 并提供 DMD 四步蒸馏模型 ([文档](#))。

3.6 LingBot 与 FLUX.3

LingBot-Video (2026) 论文: [arXiv:2607.07675](#), 采用 MoE DiT (仓库型号 30B-A3B)、机器人操作/导航数据和物理、任务完成度等多维奖励; LingBot-World 2.0 进一步支持动作交互与实时蒸馏 ([arXiv:2607.07534](#))。FLUX.3 Video (2026-07, Black Forest Labs) 目前主要有产品/API 资料, 宣称约 20 秒、关键帧和原生音频; 训练目标、VAE 与 Transformer 尚未公开, 不能进行参数级复现比较。

4 时间线与对比

时间	模型	方法演进
----	----	------

2019-21	VideoGPT、DVD-GAN	离散 token/像素自回归与 GAN
2022	Make-A-Video、Imagen Video	时空 U-Net 扩散
2023	VideoCrafter、AnimateDiff、Lumiere	时空注意力、运动模块、DiT 基础
2024	Sora、Genie、Hunyuan-Video	潜空间 DiT;latent-action 世界模型;13B 开源 DiT
2025	Wan 2.1、Hailuo-02、SANA-Video	Flow Matching、多任务开源;NCR;Linear DiT
2026	LingBot、SANA-Video2、MiniMax H3、FLUX.3	MoE 具身、混合注意力与蒸馏、统一音视频与关键帧

模型	核心范式	条件/输出	开放性
Genie	latent action+AR dynamics	动作控制、逐帧 rollout	研究原型
HunyuanVideo	13B DiT、双流到单流、3D-VAE	T2V/I2V/V2V, 约 5 秒	开源
Wan 2.1	DiT+Flow Matching、Wan-VAE	T2V/I2V/编辑	开源
Hailuo-02	NCR	6/10 秒、最高 1080p	闭源
SANA-Video2	线性 +softmax anchor、DMD	5B、720p/8 秒	开源 5B
MiniMax H3	Omni 表示、H3-VAE、原生音频	2K/15 秒、多参考	计划开放
LingBot-Video	MoE DiT、具身奖励	动作条件、T2V/TI2V	开源
FLUX.3	统一图像/视频/音频/动作	20 秒、关键帧、音频	闭源

5 榜单阅读原则

截至 2026-09-12 没有跨任务公认的单一总榜。应分别报告闭源综合质量、开源质量、效率和交互世界模型，并记录评测日期、分辨率、时长、是否含音频及人工/自动指标。建议将 FLUX.3、Veo、Sora、MiniMax H3 视为闭源第一梯队候选，将 LingBot/Wan/Hunyuan 作为开源候选，SANA-Video2 作为效率候选，LingBot-World 与 Genie 作为交互候选；名次需随公开榜单更新。

6 问题驱动的发展脉络与论文原图

本章按“瓶颈 → 方法 → 代价 → 后续影响”阅读。插图均来自论文 arXiv 源码或作者官方仓库，未自行重绘。

6.1 Genie: 为什么要从生成视频转向生成环境?

普通 T2V 模型优化的是整段视频的去噪/似然，用户只能在视频级提供文本；它没有显式的动作变量，因此难以回答“按下左键后下一帧会怎样”。Genie 的解决方案是三模块：时空视频 tokenizer、无监督 latent-action model (LAM) 和自回归 dynamics。LAM 从相邻帧反推出离散动作，dynamics 以历史 token 与动作逐帧预测下一帧。代价是自回归 rollout 比一次性扩散慢、分辨率较低；影响是把视频模型引向世界模型和具身智能。




图 1: Genie 原论文架构图: tokenizer、latent-action model 与 dynamics model。来源: [arXiv HTML](#), Fig.2/3/6。

6.2 HunyuanVideo: 如何让开源 Video DiT 接近闭源质量?

瓶颈从“能生成”变为高分辨率下的 token 数、文本对齐和训练资源。HunyuanVideo 采用 causal 3D-VAE 压缩时空 latent，使用 MLLM 编码文本，并在 DiT 中先分离视频/文本流、再合并为 single-stream 全注意力。双流阶段保留模态专门化，单流阶段增强深层融合；代价是 13B 模型显存和训练成本高。

6.3 Wan 2.1: 如何把 T2V、I2V 与编辑统一到一个开放基线?

HunyuanVideo 的高质量伴随较高部署门槛，研究者还需要一个多任务、可消费级运行的开放模型。Wan 以 Wan-VAE、DiT 和 Flow Matching 统一 T2V/I2V/V2V；文本或图像条件通过 cross-attention 注入，Flow Matching 用 ODE 速度场替代 DDPM 多步噪声预测。1.3B 版本降低显存门槛，14B 版本追求质量；但全时空注意力仍让长视频昂贵。

6.4 SANA-Video: 当 token 数成为显存瓶颈，如何生成分钟级视频?

标准 self-attention 的 $O(N^2)$ 成本随帧数迅速增长。SANA-Video 将注意力重写为线性形式，并用 block-wise causal KV cache 保存固定大小的状态；SANA-Video 2.0 再混入




图 2: HunyuanVideo 官方架构图（Causal 3D-VAE、文本编码器与 DiT）。来源：Tencent HunyuanVideo 官方仓库。




图 3: Wan 原论文 Video DiT 架构图。来源：arXiv HTML, Fig.9/10。

softmax anchor 恢复部分精细对应，并用 DMD 蒸馏到 4 步。它牺牲部分全局精确匹配，换取长视频和低延迟。




图 4: SANA-Video 原论文模型总览。来源: [arXiv HTML](#), Fig.2。

6.5 LingBot-Video: 如何把“好看”推进到“可执行”?

面向机器人时，仅有互联网视频的审美和文本对齐不够，还需要物理合理性、动作语义和任务完成度。LingBot-Video 使用稀疏 MoE DiT，让每个 token 只激活少量专家；数据混合互联网视频、操作/导航/第一视角轨迹；后训练加入物理与任务奖励。它保留扩散模型的画质，同时比 dense 大模型更省激活计算，但训练、路由稳定性和评测更加复杂。

6.6 如何比较这些图?

沿三条轴阅读: 表示从离散 token 到连续 VAE latent; 动力学从 AR 下一帧到扩散/Flow ODE; 计算组织从 dense attention 到 linear attention 和 MoE。Genie 最强调动作因果性, HunyuanVideo/Wan 最强调通用视觉质量, SANA 最强调内存和速度, LingBot 最强调物理与任务可执行性。

7 原图资产索引

- Genie: [figures/original/genie/genie_architecture.png](#)。
- HunyuanVideo: [figures/original/hunyuanvideo_overall.png](#)。
- Wan: [figures/original/wan/video_dit/dit_arch.pdf](#)。
- SANA-Video: [figures/original/sana/model.pdf](#)。
- LingBot-Video: [figures/original/lingbot/architecture/architecture.pdf](#)。




图 5: LingBot-Video 原论文架构图。来源: [arXiv HTML](#), Fig.2。

8 世界模型延伸阅读

- [Xun Huang: From Video Generation to Video World Models](#): 区分视觉逼真、交互、规划和记忆，并讨论视频生成与 3D 世界模型的互补关系。
- [Video World Models](#): 解释双向扩散的因果局限，以及 Self-Forcing、检索增强和长上下文记忆。
- [Long-Context State-Space Video World Models](#): 用 block-wise SSM 扩展时间记忆。
- [Learning World Models for Interactive Video Generation](#): 分析误差累积与全局状态条件。
- [Can Video World Models Track Unobserved World States?](#): 从不可见状态外推检验世界模型是否真正有记忆。

9 2025–2026 扩展：代表性 SOTA 与架构进展

9.1 Step-Video-T2V：深压缩 VAE 与视频 DPO




图 6: Step-Video-T2V 原论文模型架构。来源: [arXiv:2502.10248](#)。

30B 级 Video DiT 的瓶颈是时空 token 数和伪影。Step-Video 采用 8 倍时间、16x16 空间压缩的 Video-VAE、双语文本编码器、3D full-attention DiT、Flow Matching 与 Video-DPO；代价是复杂物理交互仍有限。

9.2 HunyuanVideo 1.5：选择性滑窗注意力与级联超分




图 7: HunyuanVideo 1.5 原论文架构。来源：arXiv:2511.18870。

HunyuanVideo 1.5 用 selective/sliding tile attention 减少无效交互，基础 DiT 后接视频超分网络；它回答了高清质量与推理速度的矛盾。

9.3 Epona：视频世界模型与轨迹规划解耦




图 8: Epona 原论文流程图。来源：arXiv:2506.24113。

Epona 用 causal transformer 建模 latent dynamics，再由两个扩散分支分别生成未来视频和车辆轨迹，并用 chain-of-forward 训练缓解 rollout 误差；它把渲染与规划放入同一世界模型。

9.4 SkyReels V2–V4: 长片、参考一致性和音视频统一

SkyReels-V2 引入 shot-aware caption、motion RL 与 diffusion forcing; V3 统一参考图 I2V、延长和音频引导; V4 使用 dual-stream MMDiT, 将生成、修补和编辑统一为条件 inpainting。论文: [V2](#)、[V3](#)、[V4](#)。

9.5 LanDiff、FlashVideo 与 FSVideo: 语义先行和极限加速

LanDiff 用高压缩 1D 语义 token 让语言模型先规划、扩散模型后精修; FlashVideo 用低分辨率大模型保证语义与运动, 再用约 4 步 Flow Matching 补高清细节; FSVideo 在高度压缩 latent 中加入 layer memory 和多分辨率 refiner。论文: [LanDiff](#)、[FlashVideo](#)、[FSVideo](#)。

9.6 长视频稳定性: Endless World、Cycle-World、Bagger 与 Diagonal Distillation

这些工作都处理自回归 exposure bias 与误差累积: Endless World 注入全局 3D 特征, Cycle-World 用反向预测和 cycle guidance, Bagger 从自身错误 rollout 聚合纠正轨迹, Diagonal Distillation 让早期 chunk 使用更多去噪步、后续 chunk 使用更少步。论文: [Endless World](#)、[Cycle-World](#)、[Bagger](#)、[Diagonal Distillation](#)。

10 Xun Huang 博客的统一视角

Xun Huang 将视频世界模型按能力分为 faithfulness、interactivity、planning 与 statefulness 四层: 画面逼真只是起点, 模型还要能接受动作、评估轨迹并维护跨长时/多视角的隐藏状态。因此, VBench 或人类美学分数不能单独证明世界模型能力。

架构演进也可归纳为三条线: causal/self-forcing 将双向教师转为可流式 rollout; SSM、线性注意力、KV cache 与显式 world-state 解决长上下文; 3D 几何、相机和动作条件把像素预测推进到可执行模拟。Genie、SANA-WM、LingBot、Epona、Endless World 和 WorldWeaver 分别代表这些取舍。博客: [From Video Generation to Video World Models](#)。

文献检索说明

2025–2026 扩展部分使用 DeepXiv CLI 的 `deepxiv search` 语义检索, 并对入选论文用 arXiv HTML/源码核对方法与架构图。